

# Машинное обучение. Метрические методы

Алексей Колесов

Белорусский государственный университет

8 ноября 2017 г.

# Метод ближайших соседей

- определение ответа для объекта по ответам близких объектов
- гипотеза компактности и непрерывности
- lazy learning

# Содержание

- 1 Метод ближайших соседей
- 2 Анализ метода ближайших соседей  $k = 1$ 
  - Анализ 1-NN
  - Проклятие размерности
- 3 Обобщения метода

# Метод ближайших соседей ( $k$ -NN)

- пусть на  $X$  определена метрика  $\rho$
- для  $X = \mathbb{R}^d$  естественна  $\rho(x, x') = \sqrt{\sum_{i=1}^d (x_i - x'_i)^2}$
- пусть  $\pi_1(x), \dots, \pi_m(x)$  — объекты  $S$ , упорядоченные по  $\rho(x, x_i)$

---

## Алгоритм 1 $k$ -NN

---

**Вход:**  $S = ((x_1, y_1), \dots, (x_m, y_m))$ ;  $y_i \in [k]$

1: **return**  $h(x) \in \operatorname{argmax}_{y \in Y} |\{y_{\pi_i(x)} = y : i \leq k\}|$

---

Для  $k = 1$  получаем  $h_S(x) = y_{\pi_1(x)}$

## $k$ -NN для регрессии

- для задач регрессии естественней:  $h_S(x) = \frac{1}{k} \sum_{i=1}^k y_{\pi_i(x)}$
- также часто применяют:

$$h_S(x) = \sum_{i=1}^k \frac{\rho(x, x_{\pi_i(x)})}{\sum_{j=1}^k \rho(x, x_{\pi_j(x)})} y_{\pi_i(x)}$$

# Содержание

- 1 Метод ближайших соседей
- 2 Анализ метода ближайших соседей  $k = 1$ 
  - Анализ 1-NN
  - Проклятие размерности
- 3 Обобщения метода

# Анализ

- асимптотически  $k$ -NN приближается оптимальному решающему правилу (при «хороших» распределениях)
- мы хотим анализ для конечного  $m$
- покажем, что можно достичь оценки  $2L_D(h^*) + \epsilon$ , где  $\epsilon$  зависит от  $m$

## Предположения и обозначения

- задача бинарной классификации с 0 – 1 функцией потерь
- $X = [0, 1]^d$ ,  $\rho$ -евклидова
- $D_x$  — маргинальное распределение  $x$ ,  $\eta(x) = \mathbb{P}[y = 1|x]$
- напомним, что  $h^*(x) = 1_{\eta(x) > 1/2}$
- предположим, что  $|\eta(x) - \eta(x')| \leq c\|x - x'\|$



## Оценка для 1-NN

### Оценка для 1-NN

Пусть  $S = (x_1, y_1), \dots, (x_m, y_m)$ ,  $h_S$  — 1-NN гипотеза,  $h^*$  — оптимальное решающее правило. Тогда:

$$\mathbb{E}_{S \sim D^m} [L_D(h_S)] \leq 2L_D(h^*) + c \mathbb{E}_{S \sim D^m, x \sim D} [\|x - x_{\pi_1(x)}\|]$$

## Доказательство

Хотим:

$$\mathbb{E}_{S \sim D^m} [L_D(h_S)] \leq 2L_D(h^*) + c \mathbb{E}_{S \sim D^m, x \sim D} [\|x - x_{\pi_1(x)}\|]$$

- $L_D(h_S) = \mathbb{E}_{(x,y) \sim D} [1_{h_S(x) \neq y}]$
- $L_D(h_S)$  — вероятность получить  $S$ , затем ещё  $(x, y)$ , такой что класс  $\pi_1(x)$  не равен  $y$
- $L_D(h_S)$  — вероятность получить  $S_x = (x_1, \dots, x_m)$ , затем  $x \sim D_x$ , затем найти  $\pi_1(x)$  и выбрать  $y \sim \eta(x)$  и  $y_{\pi_1(x)} \sim \eta(\pi_1(x))$ , так чтоб метки не совпали

## Доказательство

Хотим:

$$\mathbb{E}_{S \sim D^m} [L_D(h_S)] \leq 2L_D(h^*) + c \mathbb{E}_{S \sim D^m, x \sim D} [\|x - x_{\pi_1(x)}\|]$$

Распишем:

$$\mathbb{E}_S [L_D(h_S)] = \mathbb{E}_{S_x \sim D_x^m, x \sim D_x, y \sim \eta(x), y' \sim \eta(\pi_1(x))} [1_{y \neq y'}] \quad (1)$$

$$= \mathbb{E}_{S_x \sim D_x^m, x \sim D_x} \left[ \mathbb{P}_{y \sim \eta(x), y' \sim \eta(\pi_1(x))} [y \neq y'] \right] \quad (2)$$

## Доказательство

Хотим:

$$\mathbb{E}_{S \sim D^m} [L_D(h_S)] \leq 2L_D(h^*) + c \mathbb{E}_{S \sim D^m, x \sim D} [\|x - x_{\pi_1(x)}\|]$$

Распишем:

$$\mathbb{P}_{y \sim \eta(x), y' \sim \eta(x')} [y \neq y'] = \eta(x')(1 - \eta(x)) + (1 - \eta(x'))\eta(x) \quad (3)$$

$$= 2\eta(x)(1 - \eta(x)) + (\eta(x) - \eta(x'))(2\eta(x) - 1) \quad (4)$$

$$\leq 2\eta(x)(1 - \eta(x)) + c\|x - x'\| \quad (5)$$

## Доказательство

Хотим:

$$\mathbb{E}_{S \sim D^m} [L_D(h_S)] \leq 2L_D(h^*) + c \mathbb{E}_{S \sim D^m, x \sim D} [\|x - x_{\pi_1(x)}\|]$$

Получили:

$$\mathbb{E}_S [L_D(h_S)] \leq \mathbb{E}_x [2\eta(x)(1 - \eta(x))] + c \mathbb{E}_{S, x} [\|x - x_{\pi_1(x)}\|]$$

Заметим:

$$L_D(h^*) = \mathbb{E}_x [\min\{\eta(x), 1 - \eta(x)\}] \geq \mathbb{E}_x [\eta(x)(1 - \eta(x))]$$

# Лемма

## Безымянная лемма

Пусть  $C_1, \dots, C_r$  множество подмножеств  $X$ . Пусть  $S$  — множество из  $m$  объектов из  $X$ , выбранных независимо с одинаковым распределением. Тогда:

$$\mathbb{E}_{S \sim D^m} \left[ \sum_{i: C_i \cap S = \emptyset} \mathbb{P}[C_i] \right] \leq \frac{r}{me}$$

## Доказательство

Хотим:

$$\mathbb{E}_{S \sim D^m} \left[ \sum_{i: C_i \cap S = \emptyset} \mathbb{P}[C_i] \right] \leq \frac{r}{me}$$

- $\mathbb{E}_{S \sim D^m} \left[ \sum_{i: C_i \cap S = \emptyset} \mathbb{P}[C_i] \right] = \sum_{i=1}^r \mathbb{P}[C_i] \mathbb{P}[C_i \cap S = \emptyset]$
- $\mathbb{P}[C_i \cap S = \emptyset] = (1 - P(C_i))^m \leq e^{-P[C_i]m}$
- $\mathbb{E}_{S \sim D^m} \left[ \sum_{i: C_i \cap S = \emptyset} \right] \leq \sum_{i=1}^r \mathbb{P}[C_i] e^{-\mathbb{P}[C_i]m} \leq r \max_i \mathbb{P}[C_i] e^{-\mathbb{P}[C_i]m}$
- $\max_{\alpha} \alpha e^{-m\alpha} \leq \frac{1}{me}$

## Оценка для 1-NN

### Оценка для 1-NN

Пусть  $S = (x_1, y_1), \dots, (x_m, y_m)$ ,  $h_S$  — 1-NN гипотеза,  $h^*$  — оптимальное решающее правило. Тогда:

$$\mathbb{E}_{S \sim D^m} [L_D(h_S)] \leq 2L_D(h^*) + 4c\sqrt{d}m^{-\frac{1}{d+1}}$$




## Доказательство

- возьмём целое число  $T$  и положим  $\epsilon = 1/T$ , и положим сетку из  $r = T^d$  кубиков со стороной  $\epsilon$  ( $C_1, \dots, C_r$ )
- для любых  $x, x'$  из одного кубика:  $\|x - x'\| \leq \sqrt{d}\epsilon$
- для любых  $x, x'$ :  $\|x - x'\| \leq \sqrt{d}$

$$\mathbb{E}_{x,S} [\|x - x_{\pi_1(x)}\|] \leq \mathbb{E}_S \left[ \mathbb{P} \left[ \bigcup_{i: C_i \cup S = \emptyset} \right] \sqrt{d} + \mathbb{P} \left[ \bigcup_{i: C_i \cup S \neq \emptyset} \right] \epsilon \sqrt{d} \right]$$

$$\mathbb{E}_{x,S} [\|x - x_{\pi_1(x)}\|] \leq \sqrt{d} \left( \frac{r}{me} + \epsilon \right)$$



## Доказательство

Имеем:

$$\mathbb{E}_{x,S} [\|x - x_{\pi_1(x)}\|] \leq \sqrt{d} \left( \frac{r}{me} + \epsilon \right)$$

Подставив  $r = (1/\epsilon)^d$  и  $\epsilon = 2m^{-1/(d+1)}$ , получим:

$$\mathbb{E}_{S \sim D^m} [L_D(h_S)] \leq 2L_D(h^*) + 4c\sqrt{d}m^{-\frac{1}{d+1}}$$

# Проклятие размерности

- $4c\sqrt{d}m^{-\frac{1}{d+1}}$  растёт с  $c$  и  $d$
- чтоб получить оценку  $\leq \epsilon$ , необходимо выбрать  $m \geq (4c\sqrt{d}/\epsilon)^{d+1}$
- размер выборки должен расти экспоненциально с размерностью пространства

# NoFLT

## NoFLT для липшицевых распределений

Для любого  $c > 1$  и решающего правила  $L$  существует распределение  $[0, 1]^d \times 0, 1$ , такое что  $\eta(x)$  является  $c$ -липшицевой, ошибка оптимального решающего правила равна нулю, но для размера выборки  $m \leq (c + 1)^d / 2$  ошибка  $L$  не меньше  $1/4$

**Доказательство:** если выбрать решётку с шагом  $1/c$  (из  $(c + 1)^d$  точек), то любая функция распределения будет  $c$ -липшицевой  $\Rightarrow$  NoFLT.

# Применение

- наивный алгоритм работает за  $\mathcal{O}(dm)$
- алгоритмы из вычислительной геометрии требуют  $\mathcal{O}(d^{\mathcal{O}(1)} \log(m))$ , но занимают  $m^{\mathcal{O}(d)}$  памяти
- чаще всего применяют приближённые алгоритмы (local-sensitive hashing)

# Содержание


- 1 Метод ближайших соседей
- 2 Анализ метода ближайших соседей  $k = 1$ 
  - Анализ 1-NN
  - Проклятие размерности
- 3 Обобщения метода

## Предположения

- гипотеза компактности: близкие объекты, как правило, лежат в одном классе
- гипотеза непрерывности: близким объектам соответствуют близкие ответы
- близкие объекты, у которых  $\rho(x, x')$  мало

## Примеры расстояний

- для сайтов в интернете: минимальное количество переходов по ссылкам
- для текстов: редакторское расстояние Левенштейна
- для сигналов: энергия сжатия





# Обобщённый метрический классификатор

Обобщённый метрический классификатор:

$$h_S(x) = \operatorname{argmax}_{y \in Y} \underbrace{\sum_{i=1}^m 1_{[y_{\pi_i(x)}=y]} w(i, x)}_{\Gamma_y(x)}$$

- $w(i, x)$  – степень важности  $i$ -го соседа
- $\Gamma_y(x)$  — оценка близости объекта  $x$  к классу  $y$

# 1-NN

$$w(i, x) = 1_{i=1}$$

## Преимущества:

- простота реализации
- интерпретируемость решения (вывод на основе прецедентов)

## Недостатки:

- неустойчивость к шуму
- отсутствие настраиваемых параметров
- низкое качество классификации
- необходимо хранить всю выборку

## $k$ -NN

$$w(i, x) = 1_{i \leq k}$$


Преимущества:

- менее чувствителен к шуму
- возможность настраивать  $k$

Недостатки:

- неоднозначность классификации  $\Gamma_y(x) = \Gamma_{y'}(x)$

## Пример



## Пример



## Метод $k$ взвешенных соседей

$$w(i, x) = 1_{i \leq k} w_i$$

Эвристики:

- $w_i = \frac{k+1-i}{k}$
- $w_i = q^i$  для  $0 < q < 1$

Вопросы:

- как выбрать, какие веса использовать?
- может лучше, чтоб  $w_i$  зависел от  $\rho(x, x')$ , а не  $i$ ?

## Метод парзеновского окна

$$w(i, x) = K\left(\frac{\rho(x, x_{\pi_i(x)})}{h}\right)$$

$K(r)$  — ядро, не возрастает и положительно на  $[0, 1]$

**Метод парзеновского окна фиксированной ширины:**

$$h_{S,w,K}(x) = \operatorname{argmax}_{y \in Y} \sum_{i=1}^m 1_{[y_{\pi_i(x)}=y]} K\left(\frac{\rho(x, x_{\pi_i(x)})}{w}\right)$$

**Метод парзеновского окна переменной ширины:**


$$h_{S,k,K}(x) = \operatorname{argmax}_{y \in Y} \sum_{i=1}^m 1_{[y_{\pi_i(x)}=y]} K\left(\frac{\rho(x, x_{\pi_i(x)})}{\rho(x, x_{\pi_{k+1}(x)})}\right)$$

Надо выбирать:

- ширину окна
- ядро

## Пример


0.05






## Пример

0.3




# Пример

1.0



## Пример

5.0



# Метод потенциальных функций

$$w(i, x) = \gamma_i K \left( \frac{\rho(x, x_{\pi_i(x)})}{h_i} \right)$$

Классификатор:

$$h_S(x) = \operatorname{argmax}_{y \in Y} \sum_{i=1}^m 1_{[y_{\pi_i(x)}=y]} \gamma_i K \left( \frac{\rho(x, x_{\pi_i(x)})}{h_i} \right)$$

Аналогия:

- $\gamma_i$  — величина заряда
- $h_i$  — радиус действия
- $y_i$  — знак заряда

## Метод потенциальных функций — линейный классификатор

$$w(i, x) = \gamma_i K \left( \frac{\rho(x, x_{\pi_i(x)})}{h_i} \right)$$

Классификатор:

$$h_S(x) = \operatorname{argmax}_{y \in Y} \sum_{i=1}^m 1_{[y_{\pi_i(x)}=y]} \gamma_i K \left( \frac{\rho(x, x_{\pi_i(x)})}{h_i} \right) = \operatorname{sign} \sum_{i=1}^m \gamma_i y_i K_i$$

Аналогия:

- $y_i K_i$  — признаковое описание
- $\gamma_i$  — линейные коэффициенты

# Содержание

- 1 Метод ближайших соседей
- 2 Анализ метода ближайших соседей  $k = 1$ 
  - Анализ 1-NN
  - Проклятие размерности
- 3 Обобщения метода

# Итоги

- разобрали метод ближайших соседей
- рассмотрели обобщения метода ближайших соседей
- доказали оценки для метода ближайших соседней ( $k = 1$ )

# Литература

- Shai Shalev-Shwartz and Shai Ben-David — Understanding Machine Learning: From theory to algorithms (глава 19)
- К.Воронцов — метрические методы